Reconocimiento de tipos de música con *machine learning* ¶

- **Autor:** Edwin Jahir Rueda Rojas
- **Email:** ejrueda95g@gmail.com (mailto:ejrueda95g@gmail.com)
- **site:** www.edwinrueda.com (http://www.edwinrueda.com)

Herramientas utilizadas:

- Python v3.6.5
- Pandas v0.23.0
- Numpy v1.14.3
- sklearn v0.19.1
- matplotlib v2.2.2
- xgboost v0.82

- link de la competición: https://www.kaggle.com/c/music4ed/overview (https://www.kaggle.com/c/music4ed/overview)

In [1]:
```
import pandas as pd
import numpy as np
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import GradientBoostingClassifier
from sklearn.preprocessing import minmax_scale
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
```

Cargando los datos de entrenamiento:

- se cargan los datos de entrenamiento, el cual es un archivo "csv" con 12495 registros.

In [9]:
```
1 data_train = pd.read_csv("./data/genresTrain.csv")
2 data_train.head()
```

Out[9]:

	PAR_TC	PAR_SC	PAR_SC_V	PAR_ASE1	PAR_ASE2	PAR_ASE3	PAR_ASE4	PAR_ASE5	PAR_ASE6	PAR_ASE7	...	PAR_3RMS_TC
0	2.5788	481.45	76989.0	-0.12334	-0.11578	-0.11176	-0.10412	-0.106100	-0.11026	-0.11375	...	0.0020
1	2.7195	1405.30	825380.0	-0.17655	-0.18323	-0.17773	-0.17057	-0.166440	-0.16174	-0.15371	...	0.0059
2	2.5351	601.09	686240.0	-0.13940	-0.13251	-0.11486	-0.10173	-0.099342	-0.10936	-0.12668	...	0.0027
3	2.4465	637.73	122580.0	-0.14995	-0.14802	-0.13800	-0.12927	-0.125150	-0.12340	-0.12159	...	0.0025
4	2.5657	776.86	124010.0	-0.16863	-0.16112	-0.15935	-0.15120	-0.140340	-0.13002	-0.12804	...	0.0027

5 rows × 192 columns

In [10]:
```
1 print("Dimesionalidad de los datos: ", data_train.shape)
```

```
Dimesionalidad de los datos:  (12495, 192)
```

Etiquetas:

- Debido a que el *target* está dado en texto, este se tiene que cambiar a valores númericos, para eso etiquetamos de 1 a 6 las diferentes clases.

In [11]:
```
1 data_train.loc[data_train.loc[:,"GENRE"]=="Blues", "GENRE"] = 1
2 data_train.loc[data_train.loc[:,"GENRE"]=="Classical", "GENRE"] = 2
3 data_train.loc[data_train.loc[:,"GENRE"]=="Jazz", "GENRE"] = 3
4 data_train.loc[data_train.loc[:,"GENRE"]=="Metal", "GENRE"] = 4
5 data_train.loc[data_train.loc[:,"GENRE"]=="Pop", "GENRE"] = 5
6 data_train.loc[data_train.loc[:,"GENRE"]=="Rock", "GENRE"] = 6
```

Cargando los datos de test

- Se cargan los datos de test, los cuales van a ser subidos a kaggle, los cuales tienen 5225 registros.

In [13]:
```
data_test = pd.read_csv("./data/genresTest.csv")
print("Dimensionalidad de los datos: ", data_test.shape)
data_test.head()
```

```
Dimensionalidad de los datos:  (5225, 191)
```

Out[13]:

	PAR_TC	PAR_SC	PAR_SC_V	PAR_ASE1	PAR_ASE2	PAR_ASE3	PAR_ASE4	PAR_ASE5	PAR_ASE6	PAR_ASE7	...	PAR_2RMS_TC
0	2.5851	887.72	203130.0	-0.17260	-0.16509	-0.15114	-0.14272	-0.13747	-0.13437	-0.12990	...	0.0144
1	2.4621	370.86	4835.0	-0.16553	-0.16676	-0.16022	-0.15304	-0.14354	-0.13443	-0.12450	...	0.0071
2	2.5894	536.33	59175.0	-0.14433	-0.15838	-0.15151	-0.13966	-0.12591	-0.11795	-0.11744	...	0.0097
3	2.4876	1053.70	147250.0	-0.12813	-0.11979	-0.12223	-0.11881	-0.12020	-0.12702	-0.13608	...	0.0205
4	2.7968	354.90	7610.9	-0.16335	-0.16976	-0.17196	-0.16772	-0.16637	-0.15903	-0.13995	...	0.0048

5 rows × 191 columns

Matriz de correlación:

- Se genera la matriz de correlación para los datos como en los notebook anexos a este repositorio, teniendo en cuenta que se elimina uno de los pares de *features* que tengan una correlación superior al 0.85.

In [14]:
```
m_cor = data_train.corr()
dict_l = {}
for i in m_cor.index:
    dict_l.update({i:m_cor[m_cor[i]>.85].index})
```

In [16]:
```
cols_drop = []
for idx in dict_l:
    if not (idx in cols_drop): #si ya está para eliminar no se revisa
        for j in range(len(dict_l[idx])):
            if idx != dict_l[idx][j]: #el se quiere mantener
                if not (dict_l[idx][j] in cols_drop): #si no se a eliminado se puede eliminar
                    cols_drop.append(dict_l[idx][j])
                    #print(idx, dict_l[idx][j])

print("Número de columnas a eliminar: ", len(cols_drop))
print("---------------------------------")
print("Columnas a eliminar: ", cols_drop)
```

```
Número de columnas a eliminar:  47
---------------------------------
Columnas a eliminar:  ['PAR_ZCD', 'PAR_2RMS_TCD', 'PAR_ZCD_10FR_MEAN', 'PAR_ASE2', 'PAR_ASE4', 'PAR_
ASE5', 'PAR_ASE7', 'PAR_ASE11', 'PAR_ASE24', 'PAR_ASE26', 'PAR_ASE28', 'PAR_ASE30', 'PAR_ASEV2', 'PA
R_ASEV3', 'PAR_ASEV5', 'PAR_ASEV7', 'PAR_SFM10', 'PAR_SFM12', 'PAR_SFM14', 'PAR_SFM15', 'PAR_SFM_M',
'PAR_SFM17', 'PAR_SFM19', 'PAR_SFMV20', 'PAR_MFCCV1', 'PAR_MFCCV2', 'PAR_MFCCV3', 'PAR_MFCCV4', 'PAR
_MFCCV5', 'PAR_MFCCV6', 'PAR_MFCCV7', 'PAR_MFCCV8', 'PAR_MFCCV9', 'PAR_MFCCV10', 'PAR_MFCCV11', 'PAR
_MFCCV12', 'PAR_MFCCV13', 'PAR_MFCCV14', 'PAR_MFCCV15', 'PAR_MFCCV16', 'PAR_MFCCV17', 'PAR_MFCCV18',
'PAR_MFCCV19', 'PAR_MFCCV20', 'PAR_1RMS_TCD_10FR_MEAN', 'PAR_2RMS_TCD_10FR_MEAN', 'PAR_3RMS_TCD_10FR
_MEAN']
```

Eliminación de caracteristicas similares

- Se eliminan las caracteristicas menciondas anteriormente, reduciendo así la dimensionalidad de los datos, de 191 caracteristicas a 144, una reducción del 24,6%.

In [20]:
```
df_train_drop = data_train
df_test_drop = data_test
for idx in np.unique(cols_drop):
    df_train_drop = df_train_drop.drop(idx,axis=1)
    df_test_drop = df_test_drop.drop(idx,axis=1)
```

In [22]:
```
print("----- Nuevos datos de entrenamiento -----")
df_train_drop.head()
```

```
----- Nuevos datos de entrenamiento -----
```

Out[22]:

	PAR_TC	PAR_SC	PAR_SC_V	PAR_ASE1	PAR_ASE3	PAR_ASE6	PAR_ASE8	PAR_ASE9	PAR_ASE10	PAR_ASE12	...	PAR_PEAK_
0	2.5788	481.45	76989.0	-0.12334	-0.11176	-0.11026	-0.12465	-0.13659	-0.13951	-0.13893	...	
1	2.7195	1405.30	825380.0	-0.17655	-0.17773	-0.16174	-0.14458	-0.14691	-0.15324	-0.14155	...	
2	2.5351	601.09	686240.0	-0.13940	-0.11486	-0.10936	-0.12948	-0.12599	-0.12750	-0.13485	...	
3	2.4465	637.73	122580.0	-0.14995	-0.13800	-0.12340	-0.12010	-0.12907	-0.12677	-0.13761	...	
4	2.5657	776.86	124010.0	-0.16863	-0.15935	-0.13002	-0.13167	-0.13584	-0.13075	-0.11369	...	

5 rows × 145 columns

Columnas a escalar

- Se resolvió no escalar todas las columnas ya que por procedimientos previos se vio que el rendimiento del *voting classifier* se reducia, por ende solo se escalan las caracteristicas mensionadas abajo.

  Escalado de la forma:

$$X = \frac{x_i - \overline{X}}{max(X) - min(X)}$$

- A su vez se resolvió eliminar 3 columnas las cuales tenian valores muy dispersos.

In [26]:
```
col_scalar = ["PAR_TC", "PAR_ASC", "PAR_ASS", "PAR_PEAK_RMS_TOT", "PAR_PEAK_RMS10FR_MEAN"]
col_outliers = ["PAR_SC","PAR_SC_V", "PAR_PEAK_RMS10FR_VAR"]
```

In [27]:
```python
def column_scale(df, l_cols):
    """
    df: DataFrame de entrada
    l_cols: lista de columnas a escalar
    return: retorna un df con las columnas estandarizadas así:
    (X - mean(X))/(max(X)-min(X))
    """
    for col in l_cols:
        #se cambia cada columna
        df[col] = (df[col] - np.mean(df[col]))/(max(df[col]) - min(df[col]))
        #df[col] = (df[col] - min(df[col]))/((max(df[col]) - min(df[col])))
    return df
```

In [28]:
```python
y_trdrop = df_train_drop["GENRE"]
X_trdrop = df_train_drop.drop("GENRE",axis=1)

X_trdrop = column_scale(X_trdrop, col_scalar)
X_testdrop = df_test_drop
X_testdrop = column_scale(X_testdrop, col_scalar)

X_trdrop = X_trdrop.drop(col_outliers, axis=1)

X_testdrop = X_testdrop.drop(col_outliers, axis=1)
```

In [30]:
```python
print("Porcentaje de registros por clase")
print("---------------------------------")
print("clase 1: ",np.mean(y_trdrop==1)*100)
print("clase 2: ",np.mean(y_trdrop==2)*100)
print("clase 3: ",np.mean(y_trdrop==3)*100)
print("clase 4: ",np.mean(y_trdrop==4)*100)
print("clase 5: ",np.mean(y_trdrop==5)*100)
print("clase 6: ",np.mean(y_trdrop==6)*100)
```

```
Porcentaje de registros por clase
---------------------------------
clase 1:  12.773109243697478
clase 2:  27.563025210084035
clase 3:  24.03361344537815
clase 4:  7.394957983193278
clase 5:  12.605042016806722
clase 6:  15.630252100840336
```

Se entrena un primer comité de clasificadores:

- De este comité obtendremos los registros para los cuales todos los clasificadores dijeron que el registro pertenecia a cierta clase, para así posteriormente, añadir esos nuevos registros, como reistros de entrenamiento y así volver a entrenar el comité.

In [31]:
```
from sklearn.ensemble import RandomForestClassifier, VotingClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
import xgboost as xgb
from time import time

t_i = time()
clf1 = RandomForestClassifier(n_estimators=750, class_weight="balanced_subsample")
clf2 = KNeighborsClassifier(n_neighbors=12, p=1)
clf3 = GradientBoostingClassifier(n_estimators=120, learning_rate=0.2)
clf4 = xgb.XGBClassifier(n_estimators=250, objective='multi:softprob', n_jobs=1)
clf5 = DecisionTreeClassifier()

eclf1 = VotingClassifier(estimators=[
        ('rfc', clf1), ('knn', clf2), ('gbc', clf3), ('xgb', clf4), ('dtc', clf5)], voting='hard'
eclf1 = eclf1.fit(X_trdrop, y_trdrop)
t_f = time()
print("Score en entrenamiento: ", eclf1.score(X_trdrop, y_trdrop))
print("Tiempo de entrenamieto: ", (t_f-t_i)/60, "[min]")
predict = eclf1.predict(X_testdrop)
```

```
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: DeprecationW
arning: The truth value of an empty array is ambiguous. Returning False, but in future this will res
ult in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: DeprecationW
arning: The truth value of an empty array is ambiguous. Returning False, but in future this will res
ult in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:

Score en entrenamiento:  0.9991996798719488
Tiempo de entrenamieto:  5.358525987466177 [min]

/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: DeprecationW
arning: The truth value of an empty array is ambiguous. Returning False, but in future this will res
ult in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: DeprecationW
arning: The truth value of an empty array is ambiguous. Returning False, but in future this will res
ult in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:
```

In [32]:
```
result = pd.DataFrame(data=predict.astype(int), index=np.arange(1, data_test.shape[0]+1), columns
result.index.name = "Id"
result.to_csv('./results/submission_test_141.csv')
```

Predicción:

- Se puede ver que la cantidad de registros que el comité predijo que pertenecian a la clase 4 es muy bajo.

In [33]:
```
print("clase 1: ",np.mean(predict==1)*100)
print("clase 2: ",np.mean(predict==2)*100)
print("clase 3: ",np.mean(predict==3)*100)
print("clase 4: ",np.mean(predict==4)*100)
print("clase 5: ",np.mean(predict==5)*100)
print("clase 6: ",np.mean(predict==6)*100)
```

```
clase 1:  7.751196172248803
clase 2:  24.74641148325359
clase 3:  34.48803827751196
clase 4:  1.875598086124402
clase 5:  10.832535885167465
clase 6:  20.30622009569378
```

Añadiendo registros a entrenamiento:

- Como se habló anteriormente, se toman los registros que todos los clasificadores dijeron que pertenecian a la misma clase, y se entrena otro comité con estos nuevos registros.
- **Importante:** solo se toman los registros para las clases 1, 4 y 5, ya que son las que están mas desbalanceadas.

In [34]:
```
r_class = eclf1.transform(X_testdrop)
r_class
```

```
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: DeprecationW
arning: The truth value of an empty array is ambiguous. Returning False, but in future this will res
ult in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:
```

Out[34]:
```
array([[0, 5, 0, 0, 0],
       [1, 1, 1, 1, 2],
       [1, 2, 1, 1, 1],
       ...,
       [5, 5, 5, 5, 5],
       [4, 4, 4, 4, 4],
       [5, 2, 5, 5, 5]])
```

In [35]:
```
new_data_index = []
new_class = []
index = 0
for i in r_class:
    if np.mean(i) == i[0]:
        if int(np.mean(i))+1 == 4 or int(np.mean(i))+1 == 1 or int(np.mean(i))+1 == 5: #para esco
            new_data_index.append(index)
            new_class.append(int(np.mean(i))+1)
    index += 1
```

In [37]:
```
print("Número de registros nuevos: ",len(new_class))
```

```
Número de registros nuevos:  262
```

In [38]:
```
X_trdrop = pd.concat((X_trdrop, X_testdrop.loc[new_data_index]))
y_trdrop = pd.concat((y_trdrop, pd.Series(new_class)))
```

In [40]:
```
from sklearn.ensemble import RandomForestClassifier, VotingClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
import xgboost as xgb
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis

t_i = time()
clf1 = RandomForestClassifier(n_estimators=750, class_weight="balanced_subsample")
clf2 = KNeighborsClassifier(n_neighbors=12, p=1)
clf3 = GradientBoostingClassifier(n_estimators=120, learning_rate=0.2)
clf4 = xgb.XGBClassifier(n_estimators=250, objective='multi:softprob', n_jobs=1)
clf5 = DecisionTreeClassifier()
clf6 = GaussianNB()
clf7 = LinearDiscriminantAnalysis(solver="lsqr",n_components=1)

eclf1 = VotingClassifier(estimators=[
        ('rfc', clf1), ('knn', clf2), ('gbc', clf3), ('xgb', clf4), ('dtc', clf5), ('gnb',clf6),(
                        voting='hard')

X_train, X_test, y_train, y_test = train_test_split(X_trdrop, y_trdrop, test_size=0.3, random_sta
eclf1 = eclf1.fit(X_train, y_train)

score = cross_val_score(eclf1, X_trdrop, y_trdrop, cv=10, n_jobs=2)
t_f = time()
print("Tiempo de entramiento: ", (t_f-t_i)/60, "[min]")

predict = eclf1.predict(X_test)
#result = pd.DataFrame(data=predict.astype(int), index=np.arange(1, data_test.shape[0]+1), columr
#result.index.name = "Id"
#result.to_csv('./results/submission_test_142.csv')
```

```
  if diff:
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: Deprecatio
nWarning: The truth value of an empty array is ambiguous. Returning False, but in future this will
result in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: Deprecatio
nWarning: The truth value of an empty array is ambiguous. Returning False, but in future this will
result in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:

Tiempo de entramiento:  3.699869187672933 [min]
```

```
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: DeprecationWarning: The truth value of an empty array is ambiguous. Returning False, but in future this will result in an error. Use `array.size > 0` to check that an array is not empty.
  if diff:
/home/ejrueda/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/label.py:151: Deprecatio
```

In [41]:
```
1 print("Score en cada k-fold: ", score)
```

```
Score en cada k-fold:  [0.94131455 0.9428795  0.93114241 0.92241379 0.94352941 0.94509804
 0.94745098 0.94740973 0.94897959 0.95839874]
```

In [42]:
```
1 print("Score promedio: ", np.mean(score))
```

```
Score promedio:  0.9428616756773568
```

Validación cruzada:

- Se realiza una validación cruzada del modelo, con k-fold(k=10), para medir el rendimiento del comité de clasificadores y que tanta desviación tiene el modelo.

In [50]:
```
plt.figure(figsize=(7,4))
plt.grid()
plt.title("Score", fontsize=13.5)
plt.ylabel("Score", fontsize=13.5)
plt.xlabel("k-fold (k=10)", fontsize=13.5)
plt.xticks(range(1,11),range(1,11))
plt.plot(range(1,11), score, label="score",linewidth=2)
plt.plot(range(1,11), np.ones(10)*np.mean(score), color="red", alpha=1, linestyle='--', label="me
plt.fill_between(range(1,11), score - np.std(score), score + np.std(score),color='gray',
                 alpha=0.2, label="std")
plt.legend();
```

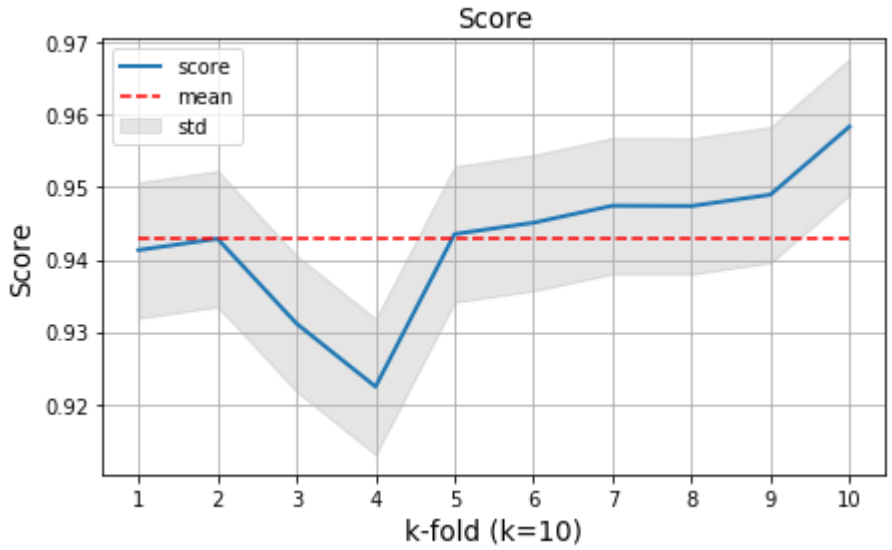

Predicción de clases:

- Se puede ver que ahora el nuevo comité de clasificadores genera predicciones mas equilibradas en cuanto al número de registros por clase.

In [51]:
```
print("clase 1: ",np.round(np.mean(predict==1)*100, 2))
print("clase 2: ",np.round(np.mean(predict==2)*100, 2))
print("clase 3: ",np.round(np.mean(predict==3)*100, 2))
print("clase 4: ",np.round(np.mean(predict==4)*100, 2))
print("clase 5: ",np.round(np.mean(predict==5)*100, 2))
print("clase 6: ",np.round(np.mean(predict==6)*100, 2))
```

```
clase 1:  13.22
clase 2:  28.71
clase 3:  22.05
clase 4:  7.52
clase 5:  13.87
clase 6:  14.63
```

Matriz de confusión:

- Se crea la matriz de confusión para ver donde el algoritmo está fallando, dada esta matiz, se puede ver que el algoritmo está confundiendo las clases 2 y 3, y por otro lado, confunde un poco la clase 3, diciendo que es 6.

In [52]:
```
from sklearn.metrics import confusion_matrix

mc = confusion_matrix(y_test, predict)
```

In [64]:

```
plt.figure(figsize=(6,6))
plt.imshow(mc, interpolation='nearest', cmap=plt.get_cmap('Reds'))
plt.title("matriz de confução", size=13)
plt.xlabel("Classes")
plt.ylabel("Classes")
plt.xticks(range(0,6),range(1,7))
plt.yticks(range(0,6),range(1,7))
plt.colorbar();
```